# Aluno: Marcelo Barros de Azevedo Vieira

In [102…
```
import numpy as np
import pandas as pd
import sys
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.decomposition import PCA
from sklearn.datasets import make_blobs, make_moons
from sklearn.preprocessing import StandardScaler
from yellowbrick.cluster import SilhouetteVisualizer
from sklearn.cluster import DBSCAN
from sklearn.preprocessing import StandardScaler
from yellowbrick.cluster import KElbowVisualizer
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn import preprocessing
from sklearn.cluster import DBSCAN
from scipy.spatial.distance import euclidean
import scipy.cluster.hierarchy as sch
```

## 1. Versão do Python: 3.13.1

In [103…
```
print(f"Versão do Python: {sys.version}")
```

```
Versão do Python: 3.13.1 | packaged by conda-forge | (main, Dec  5 2024, 2
1:09:18) [Clang 18.1.8 ]
```

## 2. Demonstrando que esta sendo utilizado o ambiente anaconda

In [104…
```
!conda info
```

```
/Users/marcelodeazevedo/miniconda3/lib/python3.12/site-packages/conda/base/context.py:201: FutureWarning: Adding 'defaults' to channel list implicitly is deprecated and will be removed in 25.3.

To remove this warning, please choose a default channel explicitly with conda's regular configuration system, e.g. by adding 'defaults' to the list of channels:

  conda config --add channels defaults

For more information see https://docs.conda.io/projects/conda/en/stable/user-guide/configuration/use-condarc.html

  deprecated.topic(

     active environment : clusterizacao
    active env location : /Users/marcelodeazevedo/miniconda3/envs/clusterizacao
            shell level : 2
       user config file : /Users/marcelodeazevedo/.condarc
 populated config files :
          conda version : 24.11.1
    conda-build version : not installed
         python version : 3.12.4.final.0
                 solver : libmamba (default)
       virtual packages : __archspec=1=m1
                          __conda=24.11.1=0
                          __osx=15.2=0
                          __unix=0=0
       base environment : /Users/marcelodeazevedo/miniconda3  (writable)
      conda av data dir : /Users/marcelodeazevedo/miniconda3/etc/conda
  conda av metadata url : None
          channel URLs : https://repo.anaconda.com/pkgs/main/osx-arm64
                         https://repo.anaconda.com/pkgs/main/noarch
                         https://repo.anaconda.com/pkgs/r/osx-arm64
                         https://repo.anaconda.com/pkgs/r/noarch
         package cache : /Users/marcelodeazevedo/miniconda3/pkgs
                         /Users/marcelodeazevedo/.conda/pkgs
       envs directories : /Users/marcelodeazevedo/miniconda3/envs
                         /Users/marcelodeazevedo/.conda/envs
                platform : osx-arm64
              user-agent : conda/24.11.1 requests/2.32.3 CPython/3.12.4 Darwin/24.2.0 OSX/15.2 solver/libmamba conda-libmamba-solver/24.7.0 libmambapy/1.5.8 aau/0.4.4 c/CO3i7I_7soBQdtRRQNdUJA s/UHS8R5GL9VcVp3DSpV0uvg e/mfYWItyiRHJdgnt46_VILA
                 UID:GID : 501:20
              netrc file : None
            offline mode : False
```

# 3.Bibliotecas utilizadas no ambiente virtual anadonda:

In [105…

```
!conda list
```

```
# packages in environment at /Users/marcelodeazevedo/miniconda3/envs/clust
erizacao:
#
# Name                    Version                   Build  Channel
anyio                     4.7.0              pyhd8ed1ab_0    conda-forge
appnope                   0.1.4              pyhd8ed1ab_1    conda-forge
argon2-cffi               23.1.0             pyhd8ed1ab_1    conda-forge
argon2-cffi-bindings      21.2.0          py313h20a7fcf_5    conda-forge
arrow                     1.3.0              pyhd8ed1ab_1    conda-forge
asttokens                 3.0.0              pyhd8ed1ab_1    conda-forge
async-lru                 2.0.4              pyhd8ed1ab_1    conda-forge
attrs                     24.2.0             pyh71513ae_1    conda-forge
babel                     2.16.0             pyhd8ed1ab_1    conda-forge
beautifulsoup4            4.12.3             pyha770c72_1    conda-forge
bleach                    6.2.0              pyhd8ed1ab_1    conda-forge
brotli-python             1.1.0           py313h3579c5c_2    conda-forge
bzip2                     1.0.8                h99b78c6_7    conda-forge
ca-certificates           2024.12.14           hf0a4a13_0    conda-forge
cached-property           1.5.2                hd8ed1ab_1    conda-forge
cached_property           1.5.2              pyha770c72_1    conda-forge
certifi                   2024.8.30          pyhd8ed1ab_0    conda-forge
cffi                      1.17.1          py313hc845a76_0    conda-forge
charset-normalizer        3.4.0              pyhd8ed1ab_1    conda-forge
comm                      0.2.2              pyhd8ed1ab_1    conda-forge
contourpy                 1.3.1                     pypi_0    pypi
cycler                    0.12.1                    pypi_0    pypi
debugpy                   1.8.11          py313h928ef07_0    conda-forge
decorator                 5.1.1              pyhd8ed1ab_1    conda-forge
defusedxml                0.7.1              pyhd8ed1ab_0    conda-forge
entrypoints               0.4                pyhd8ed1ab_1    conda-forge
exceptiongroup            1.2.2              pyhd8ed1ab_1    conda-forge
executing                 2.1.0              pyhd8ed1ab_1    conda-forge
fonttools                 4.55.3                    pypi_0    pypi
fqdn                      1.5.1              pyhd8ed1ab_1    conda-forge
h11                       0.14.0             pyhd8ed1ab_1    conda-forge
h2                        4.1.0              pyhd8ed1ab_1    conda-forge
hpack                     4.0.0              pyhd8ed1ab_1    conda-forge
httpcore                  1.0.7              pyh29332c3_1    conda-forge
httpx                     0.28.1             pyhd8ed1ab_0    conda-forge
hyperframe                6.0.1              pyhd8ed1ab_1    conda-forge
idna                      3.10               pyhd8ed1ab_1    conda-forge
importlib-metadata        8.5.0              pyha770c72_1    conda-forge
importlib_resources       6.4.5              pyhd8ed1ab_1    conda-forge
ipykernel                 6.29.5             pyh57ce528_0    conda-forge
ipython                   8.30.0             pyh707e725_0    conda-forge
isoduration               20.11.0            pyhd8ed1ab_1    conda-forge
jedi                      0.19.2             pyhd8ed1ab_1    conda-forge
jinja2                    3.1.4              pyhd8ed1ab_1    conda-forge
joblib                    1.4.2                     pypi_0    pypi
json5                     0.10.0             pyhd8ed1ab_1    conda-forge
jsonpointer               3.0.0           py313h8f79df9_1    conda-forge
jsonschema                4.23.0             pyhd8ed1ab_1    conda-forge
jsonschema-specifications 2024.10.1          pyhd8ed1ab_1    conda-forge
jsonschema-with-format-nongpl 4.23.0              hd8ed1ab_1    conda-for
ge
jupyter-lsp               2.2.5              pyhd8ed1ab_1    conda-forge
jupyter_client            8.6.3              pyhd8ed1ab_1    conda-forge
jupyter_core              5.7.2              pyh31011fe_1    conda-forge
jupyter_events            0.10.0             pyhd8ed1ab_1    conda-forge
jupyter_server            2.14.2             pyhd8ed1ab_1    conda-forge
```

```
jupyter_server_terminals  0.5.3              pyhd8ed1ab_1    conda-forge
jupyterlab                4.3.3              pyhd8ed1ab_0    conda-forge
jupyterlab_pygments       0.3.0              pyhd8ed1ab_2    conda-forge
jupyterlab_server         2.27.3             pyhd8ed1ab_1    conda-forge
kiwisolver                1.4.7                    pypi_0    pypi
krb5                      1.21.3               h237132a_0    conda-forge
libcxx                    19.1.5               ha82da77_0    conda-forge
libedit                   3.1.20191231         hc8eb9b7_2    conda-forge
libexpat                  2.6.4                h286801f_0    conda-forge
libffi                    3.4.2                h3422bc3_5    conda-forge
liblzma                   5.6.3                h39f12f2_1    conda-forge
libmpdec                  4.0.0                h99b78c6_0    conda-forge
libsodium                 1.0.20               h99b78c6_0    conda-forge
libsqlite                 3.47.2               h3f77e49_0    conda-forge
libzlib                   1.3.1                h8359307_2    conda-forge
markupsafe                3.0.2           py313ha9b7d5b_1    conda-forge
matplotlib                3.10.0                   pypi_0    pypi
matplotlib-inline         0.1.7              pyhd8ed1ab_1    conda-forge
mistune                   3.0.2              pyhd8ed1ab_1    conda-forge
nbclient                  0.10.1             pyhd8ed1ab_0    conda-forge
nbconvert-core            7.16.4             pyhff2d567_2    conda-forge
nbformat                  5.10.4             pyhd8ed1ab_1    conda-forge
ncurses                   6.5                  h7bae524_1    conda-forge
nest-asyncio              1.6.0              pyhd8ed1ab_1    conda-forge
notebook-shim             0.2.4              pyhd8ed1ab_1    conda-forge
numpy                     2.2.0                    pypi_0    pypi
openssl                   3.4.0                h39f12f2_0    conda-forge
overrides                 7.7.0              pyhd8ed1ab_0    conda-forge
packaging                 24.2               pyhd8ed1ab_2    conda-forge
pandas                    2.2.3                    pypi_0    pypi
pandocfilters             1.5.0              pyhd8ed1ab_0    conda-forge
parso                     0.8.4              pyhd8ed1ab_1    conda-forge
pexpect                   4.9.0              pyhd8ed1ab_1    conda-forge
pickleshare               0.7.5           pyhd8ed1ab_1004    conda-forge
pillow                    11.0.0                   pypi_0    pypi
pip                       24.3.1             pyh145f28c_0    conda-forge
pkgutil-resolve-name      1.3.10             pyhd8ed1ab_2    conda-forge
platformdirs              4.3.6              pyhd8ed1ab_1    conda-forge
prometheus_client         0.21.1             pyhd8ed1ab_0    conda-forge
prompt-toolkit            3.0.48             pyha770c72_1    conda-forge
psutil                    6.1.0           py313h63a2874_0    conda-forge
ptyprocess                0.7.0              pyhd8ed1ab_1    conda-forge
pure_eval                 0.2.3              pyhd8ed1ab_1    conda-forge
pycparser                 2.22               pyh29332c3_1    conda-forge
pygments                  2.18.0             pyhd8ed1ab_1    conda-forge
pyobjc-core               10.3.2          py313hb6afeec_0    conda-forge
pyobjc-framework-cocoa    10.3.2          py313hb6afeec_0    conda-forge
pyparsing                 3.2.0                    pypi_0    pypi
pysocks                   1.7.1              pyha55dd90_7    conda-forge
python                    3.13.1          h4f43103_102_cp313    conda-forg
e
python-dateutil           2.9.0.post0        pyhff2d567_1    conda-forge
python-fastjsonschema     2.21.1             pyhd8ed1ab_0    conda-forge
python-json-logger        2.0.7              pyhd8ed1ab_0    conda-forge
python_abi                3.13                    5_cp313    conda-forge
pytz                      2024.2             pyhd8ed1ab_1    conda-forge
pyyaml                    6.0.2           py313h20a7fcf_1    conda-forge
pyzmq                     26.2.0          py313h0e8b002_3    conda-forge
readline                  8.2                  h92ec313_1    conda-forge
referencing               0.35.1             pyhd8ed1ab_1    conda-forge
```

```
requests                  2.32.3             pyhd8ed1ab_1    conda-forge
rfc3339-validator         0.1.4              pyhd8ed1ab_1    conda-forge
rfc3986-validator         0.1.1              pyh9f0ad1d_0    conda-forge
rpds-py                   0.22.3          py313hdde674f_0    conda-forge
scikit-learn              1.6.0                    pypi_0    pypi
scipy                     1.14.1                   pypi_0    pypi
seaborn                   0.13.2                   pypi_0    pypi
send2trash                1.8.3              pyh31c8845_1    conda-forge
setuptools                75.6.0             pyhff2d567_1    conda-forge
six                       1.17.0             pyhd8ed1ab_0    conda-forge
sniffio                   1.3.1              pyhd8ed1ab_1    conda-forge
soupsieve                 2.5                pyhd8ed1ab_1    conda-forge
stack_data                0.6.3              pyhd8ed1ab_1    conda-forge
terminado                 0.18.1             pyh31c8845_0    conda-forge
threadpoolctl             3.5.0                    pypi_0    pypi
tinycss2                  1.4.0              pyhd8ed1ab_0    conda-forge
tk                        8.6.13               h5083fa2_1    conda-forge
tomli                     2.2.1              pyhd8ed1ab_1    conda-forge
tornado                   6.4.2           py313h90d716c_0    conda-forge
traitlets                 5.14.3             pyhd8ed1ab_1    conda-forge
types-python-dateutil     2.9.0.20241206     pyhd8ed1ab_0    conda-forge
typing-extensions         4.12.2               hd8ed1ab_1    conda-forge
typing_extensions         4.12.2             pyha770c72_1    conda-forge
typing_utils              0.1.0              pyhd8ed1ab_1    conda-forge
tzdata                    2024.2                   pypi_0    pypi
uri-template              1.3.0              pyhd8ed1ab_1    conda-forge
urllib3                   2.2.3              pyhd8ed1ab_1    conda-forge
wcwidth                   0.2.13             pyhd8ed1ab_1    conda-forge
webcolors                 24.11.1            pyhd8ed1ab_0    conda-forge
webencodings              0.5.1              pyhd8ed1ab_3    conda-forge
websocket-client          1.8.0              pyhd8ed1ab_1    conda-forge
yaml                      0.2.5                h3422bc3_2    conda-forge
yellowbrick               1.5                      pypi_0    pypi
zeromq                    4.3.5                hc1bb282_7    conda-forge
zipp                      3.21.0             pyhd8ed1ab_1    conda-forge
zstandard                 0.23.0          py313hf2da073_1    conda-forge
zstd                      1.5.6                hb46c0d2_0    conda-forge
```

## Arquivo com as bibliotecas instaladas

In [106…

```
!conda list > requirements.txt
```

## Printscreen do ambiente onde o projeto está sendo executado

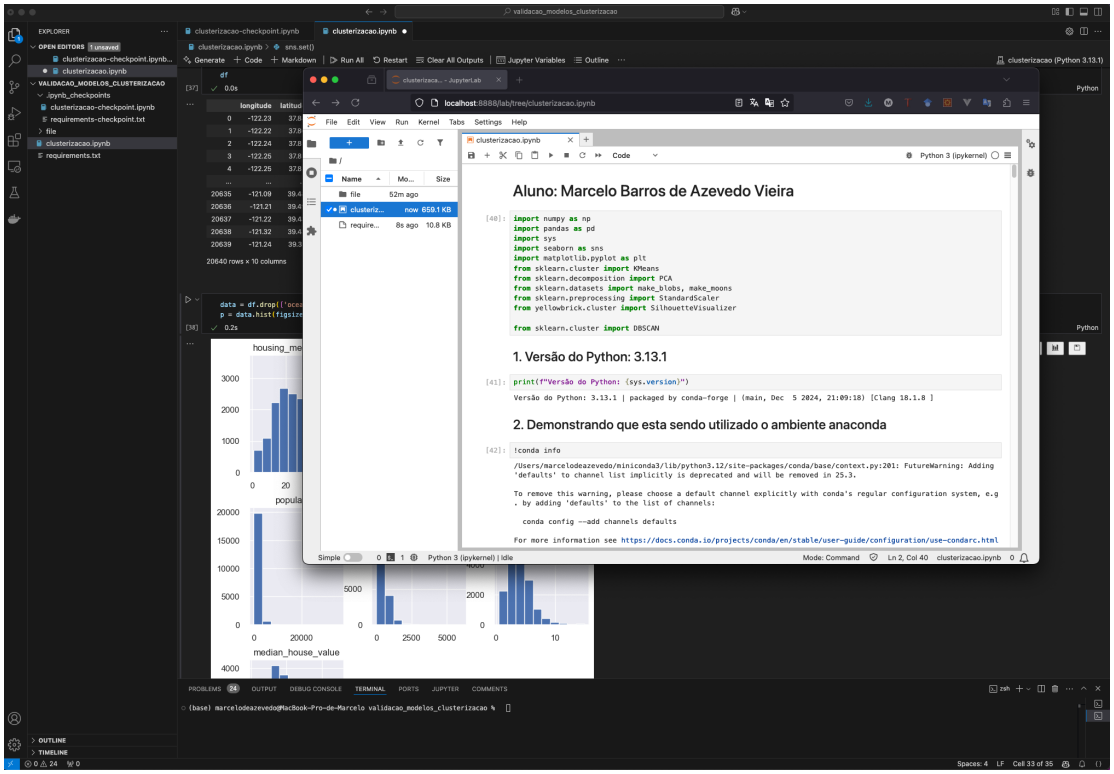


GitHub do Projeto

https://github.com/marcelobazevedo/validacao_modelos_clusterizacao

# 1.Escolha da Base de Dados

A Base de dados escolhida foi a California Housing Prices, disponível em https://www.kaggle.com/datasets/camnugent/california-housing-prices/data

# 2. Justificativa para a escolha da base de dados

O dataset "California Housing Prices" de 1990 é amplamente utilizado em projetos de aprendizado de máquina e análise de dados devido à sua relevância educacional, metodológica e histórica, mesmo com dados antigos. Ele é ideal para introduzir conceitos fundamentais como regressão, engenharia de features e aprendizado supervisionado, graças à sua estrutura clara e

documentação acessível. Além disso, muitos padrões subjacentes aos preços de imóveis, como localização, renda e densidade populacional, permanecem válidos e generalizáveis para diferentes contextos.

Seu uso é também justificado pela possibilidade de estudos históricos e comparativos, como a análise das condições do mercado imobiliário em 1990 frente a dados atuais, permitindo explorar mudanças urbanas e socioeconômicas ao longo do tempo. Por ser simplificado, o dataset oferece um ambiente controlado para aprendizado e prática antes de lidar com datasets mais complexos, consolidando habilidades analíticas essenciais.

Portanto, sua utilização é valiosa não apenas como exercício de modelagem teórica e prática, mas também para desenvolver insights generalizáveis e transferíveis para problemas modernos.

In [107…
```
df = pd.read_csv('file/housing.csv')
df.reset_index(inplace=True, drop=True)
```

In [108…
```
df
```

Out[108…

| | longitude | latitude | housing_median_age | total_rooms | total_bedrooms | po |
|---|---|---|---|---|---|---|
| **0** | -122.23 | 37.88 | 41.0 | 880.0 | 129.0 | |
| **1** | -122.22 | 37.86 | 21.0 | 7099.0 | 1106.0 | |
| **2** | -122.24 | 37.85 | 52.0 | 1467.0 | 190.0 | |
| **3** | -122.25 | 37.85 | 52.0 | 1274.0 | 235.0 | |
| **4** | -122.25 | 37.85 | 52.0 | 1627.0 | 280.0 | |
| **...** | ... | ... | ... | ... | ... | |
| **20635** | -121.09 | 39.48 | 25.0 | 1665.0 | 374.0 | |
| **20636** | -121.21 | 39.49 | 18.0 | 697.0 | 150.0 | |
| **20637** | -121.22 | 39.43 | 17.0 | 2254.0 | 485.0 | |
| **20638** | -121.32 | 39.43 | 18.0 | 1860.0 | 409.0 | |
| **20639** | -121.24 | 39.37 | 16.0 | 2785.0 | 616.0 | |

20640 rows × 10 columns

# 3. Gráfico de Faixa dinâmica e o que deve ser feito com os dados antes da clusterização

## Normalizar os dados, transformar números do tipo float para inteiros e buscar e corrigir valores nulos

In [109…
```
data = df.drop(['ocean_proximity','longitude','latitude'],axis=1)
p = data.hist(figsize = (8,10))
```

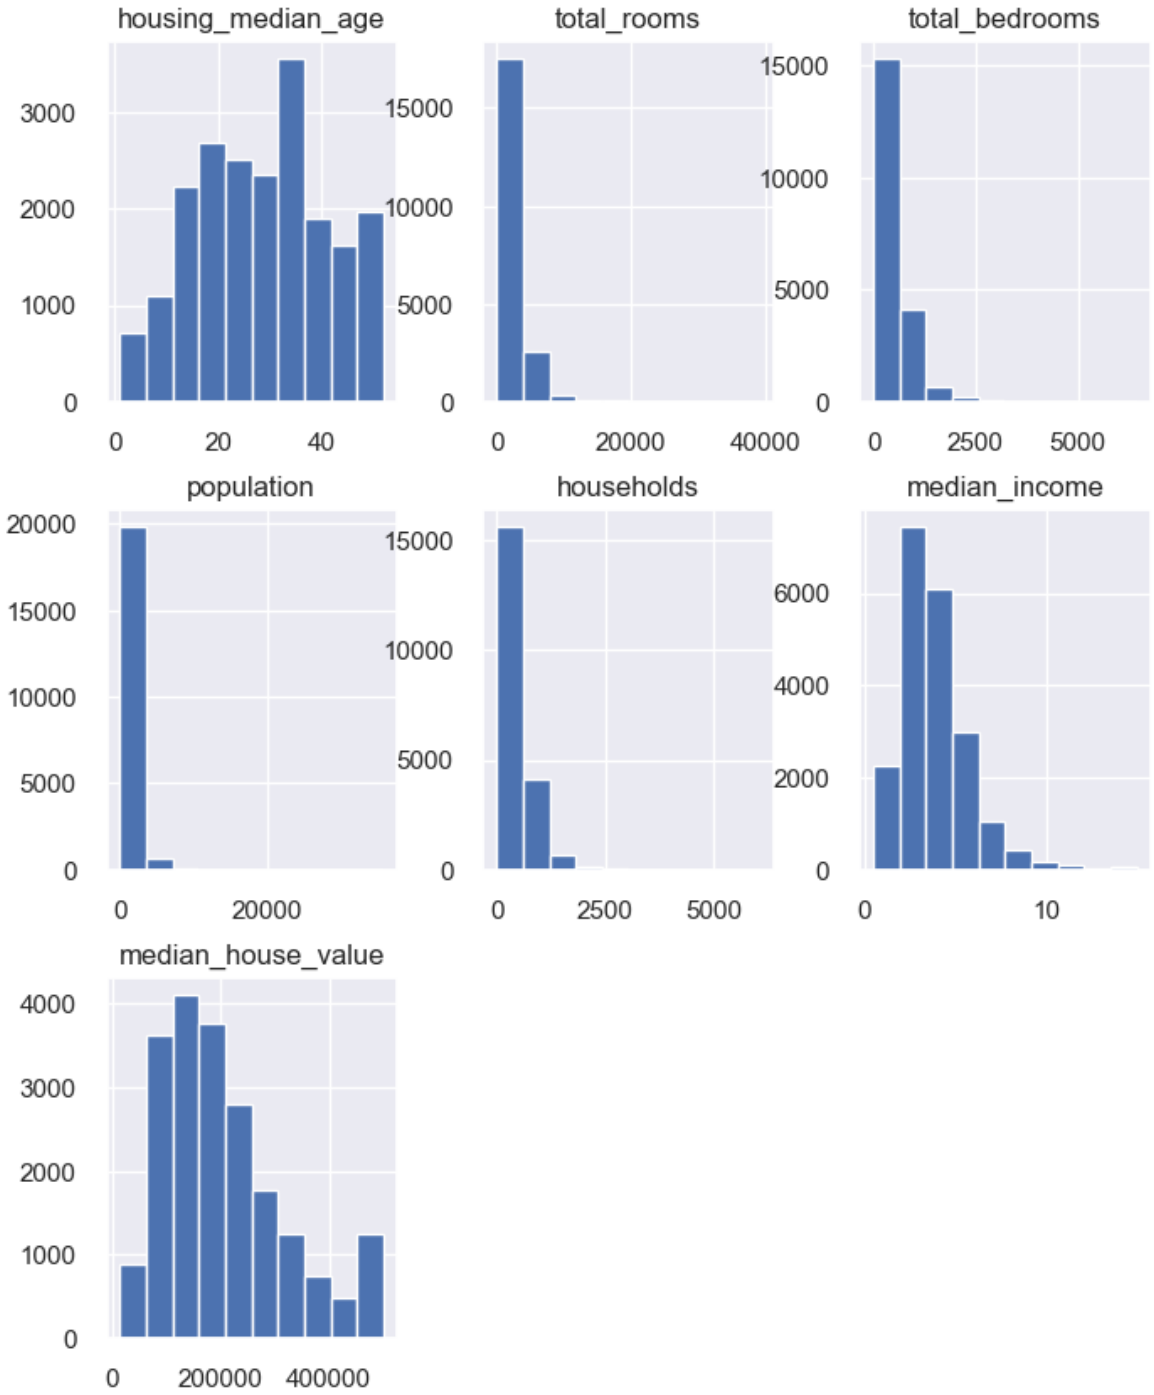


In [110…
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
 #   Column              Non-Null Count  Dtype  
---  ------              --------------  -----  
 0   longitude           20640 non-null  float64
 1   latitude            20640 non-null  float64
 2   housing_median_age  20640 non-null  float64
 3   total_rooms         20640 non-null  float64
 4   total_bedrooms      20433 non-null  float64
 5   population          20640 non-null  float64
 6   households          20640 non-null  float64
 7   median_income       20640 non-null  float64
 8   median_house_value  20640 non-null  float64
 9   ocean_proximity     20640 non-null  object 
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

In [111…
```
df.describe().T
```

Out[111…

| | count | mean | std | min | 1 |
|---|---|---|---|---|---|
| **longitude** | 20640.0 | -119.569704 | 2.003532 | -124.3500 | -121.8 |
| **latitude** | 20640.0 | 35.631861 | 2.135952 | 32.5400 | 33.9 |
| **housing_median_age** | 20640.0 | 28.639486 | 12.585558 | 1.0000 | 18.0 |
| **total_rooms** | 20640.0 | 2635.763081 | 2181.615252 | 2.0000 | 1447.7 |
| **total_bedrooms** | 20433.0 | 537.870553 | 421.385070 | 1.0000 | 296.0 |
| **population** | 20640.0 | 1425.476744 | 1132.462122 | 3.0000 | 787.0 |
| **households** | 20640.0 | 499.539680 | 382.329753 | 1.0000 | 280.0 |
| **median_income** | 20640.0 | 3.870671 | 1.899822 | 0.4999 | 2.5 |
| **median_house_value** | 20640.0 | 206855.816909 | 115395.615874 | 14999.0000 | 119600.0 |

In [112…
```
data.shape
```

Out[112… (20640, 7)

# Identificação de valores nulos

In [113…
```
print(data.isnull().sum())
```

```
housing_median_age      0
total_rooms             0
total_bedrooms        207
population              0
households              0
median_income           0
median_house_value      0
dtype: int64
```

# Correção dos valos nulos

In [114…
```
data.dropna(inplace=True)
```

In [115…
```
print(data.isnull().sum())
```

```
housing_median_age    0
total_rooms           0
total_bedrooms        0
population            0
households            0
median_income         0
median_house_value    0
dtype: int64
```

# Tranformando dados do tipo float em int

In [116…
```
data['housing_median_age'] = data['housing_median_age'].astype('int')
data['total_rooms'] = data['total_rooms'].astype('int')
data['total_bedrooms'] = data['total_bedrooms'].astype('int')
data['population'] = data['population'].astype('int')
data['households'] = data['households'].astype('int')
data['median_income'] = data['median_income'].astype('int')
data['median_house_value'] = data['median_house_value'].astype('int')
```

In [117…
```
data
```

Out[117…

| | housing_median_age | total_rooms | total_bedrooms | population | households |
|---|---|---|---|---|---|
| **0** | 41 | 880 | 129 | 322 | 126 |
| **1** | 21 | 7099 | 1106 | 2401 | 1138 |
| **2** | 52 | 1467 | 190 | 496 | 177 |
| **3** | 52 | 1274 | 235 | 558 | 219 |
| **4** | 52 | 1627 | 280 | 565 | 259 |
| **...** | ... | ... | ... | ... | ... |
| **20635** | 25 | 1665 | 374 | 845 | 330 |
| **20636** | 18 | 697 | 150 | 356 | 114 |
| **20637** | 17 | 2254 | 485 | 1007 | 433 |
| **20638** | 18 | 1860 | 409 | 741 | 349 |
| **20639** | 16 | 2785 | 616 | 1387 | 530 |

20433 rows × 7 columns

In [118…
```
corr_matrix = data.corr()
fig, ax = plt.subplots(figsize=(15, 15))
ax = sns.heatmap(corr_matrix,
                 annot=True,
```

```
                   linewidths=0.5,
                   fmt=".2f",
                   cmap="YlGnBu");
bottom, top = ax.get_ylim()
```

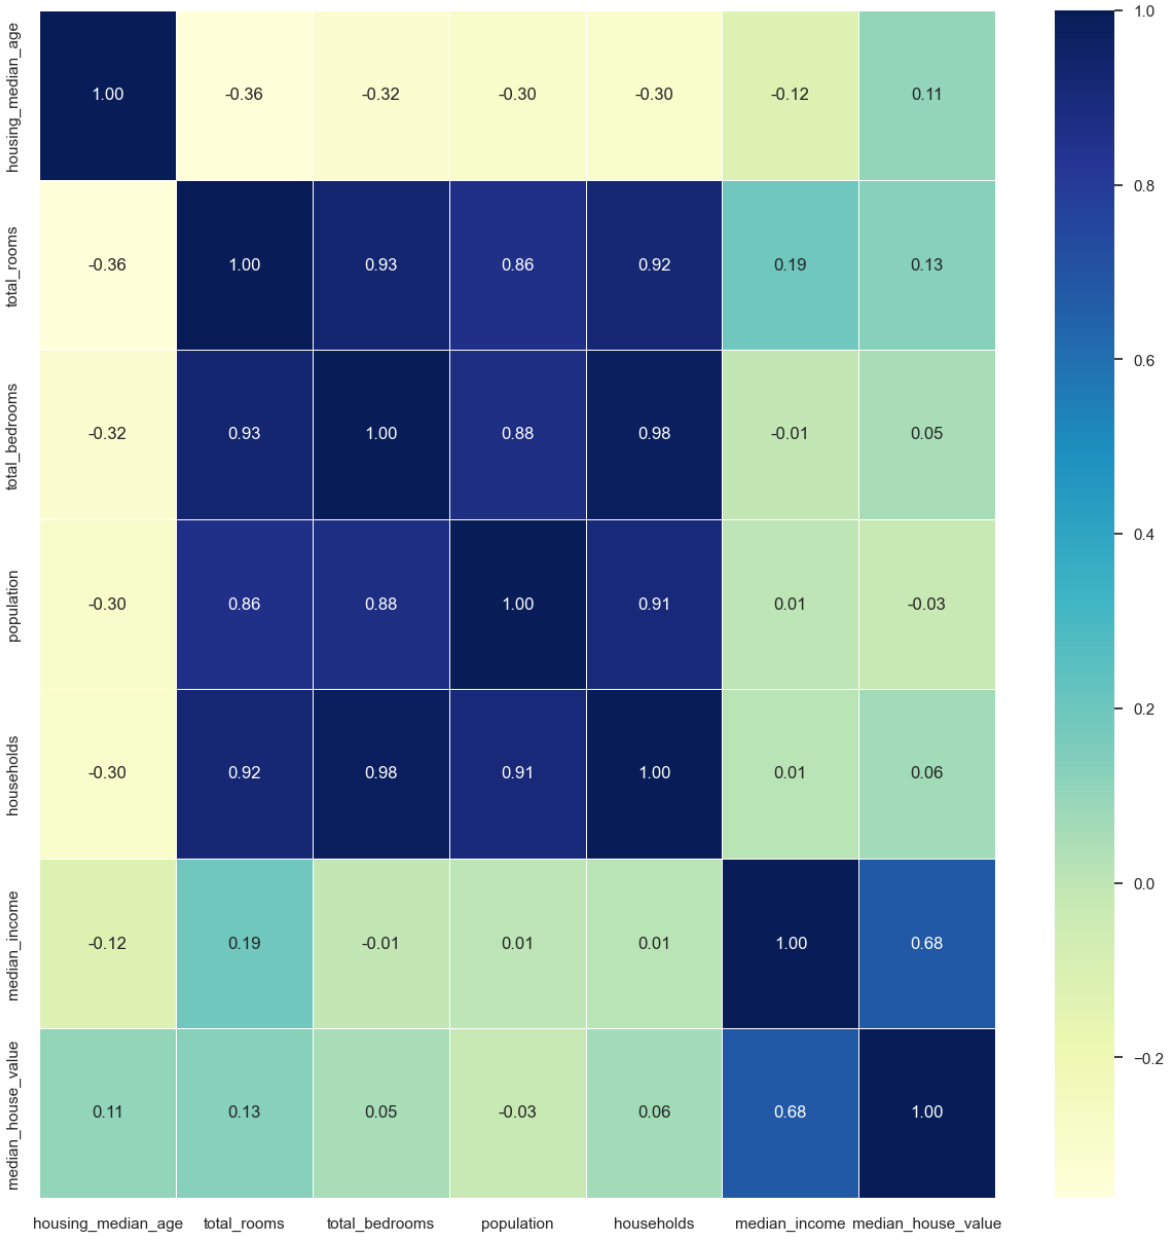


# Normalização dos dados

In [119…
```
x = data.values
x
```

Out[119…
```
array([[    41,    880,    129, ...,    126,      8, 452600],
       [    21,   7099,   1106, ...,   1138,      8, 358500],
       [    52,   1467,    190, ...,    177,      7, 352100],
       ...,
       [    17,   2254,    485, ...,    433,      1,  92300],
       [    18,   1860,    409, ...,    349,      1,  84700],
       [    16,   2785,    616, ...,    530,      2,  89400]],
      shape=(20433, 7))
```

In [120…
```
scaler = StandardScaler()
X = scaler.fit_transform(x)
```

```
X
```

Out[120…
```
array([[ 0.98216331, -0.8038126 , -0.97032521, ..., -0.97683327,
         2.38510785,  2.12881864],
       [-0.60621017,  2.0421302 ,  1.34827594, ...,  1.67037262,
         2.38510785,  1.31362603],
       [ 1.85576873, -0.53518928, -0.82556097, ..., -0.84342665,
         1.86735089,  1.25818254],
       ...,
       [-0.92388486, -0.17504183, -0.12547157, ..., -0.17377773,
        -1.23919082, -0.99247676],
       [-0.84446619, -0.35534437, -0.30583358, ..., -0.39350628,
        -1.23919082, -1.05831591],
       [-1.00330353,  0.06795473,  0.18541559, ...,  0.07995643,
        -0.72143387, -1.01759959]], shape=(20433, 7))
```

# Clusterizacão

## k-means

In [121…
```
#indice de silhueta
km = KMeans(n_clusters=2).fit(x)

fig, ax = plt.subplots(1, 1, figsize=(5, 4))

visualizer = SilhouetteVisualizer(km, ax=ax, colors='yellowbrick')
visualizer.fit(x)
visualizer.show();



km = KMeans(n_clusters=5).fit(x)

fig, ax = plt.subplots(1, 1, figsize=(5, 4))

visualizer = SilhouetteVisualizer(km, ax=ax, colors='yellowbrick')
visualizer.fit(x)
visualizer.show();


km = KMeans(n_clusters=4).fit(x)

fig, ax = plt.subplots(1, 1, figsize=(5, 4))

visualizer = SilhouetteVisualizer(km, ax=ax, colors='yellowbrick')
visualizer.fit(x)
visualizer.show();


km = KMeans(n_clusters=3).fit(x)

fig, ax = plt.subplots(1, 1, figsize=(5, 4))

visualizer = SilhouetteVisualizer(km, ax=ax, colors='yellowbrick')
visualizer.fit(x)
visualizer.show();
```

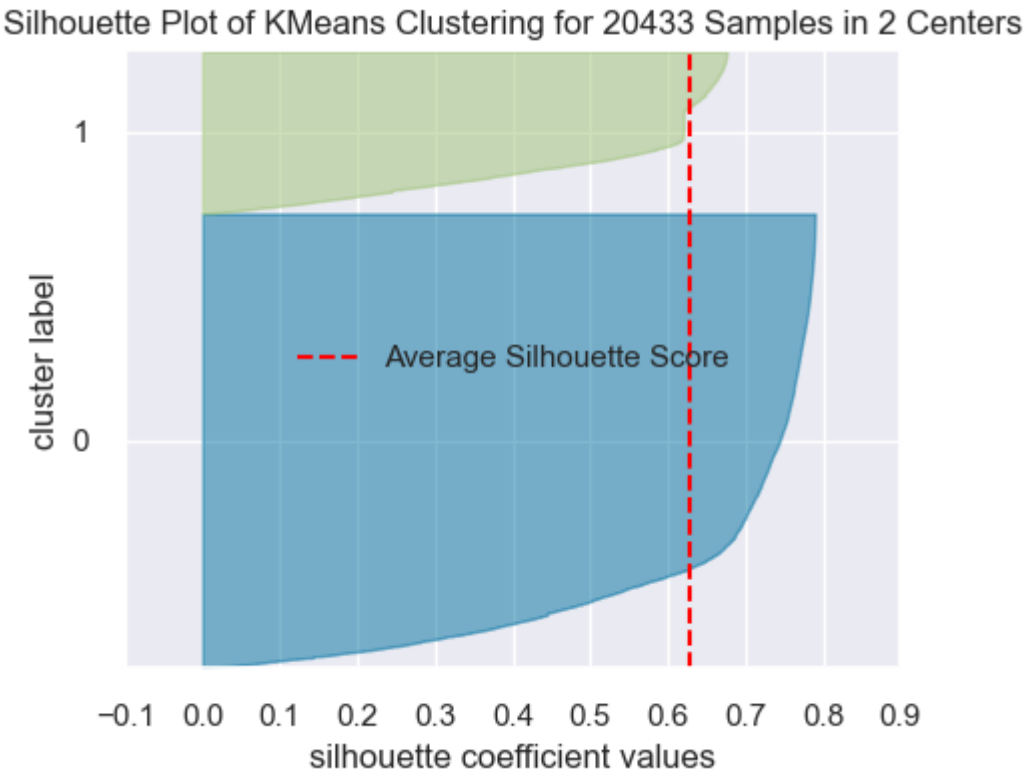
Silhouette Plot of KMeans Clustering for 20433 Samples in 2 Centers
cluster label
1
0
Average Silhouette Score
−0.1 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9
silhouette coefficient values

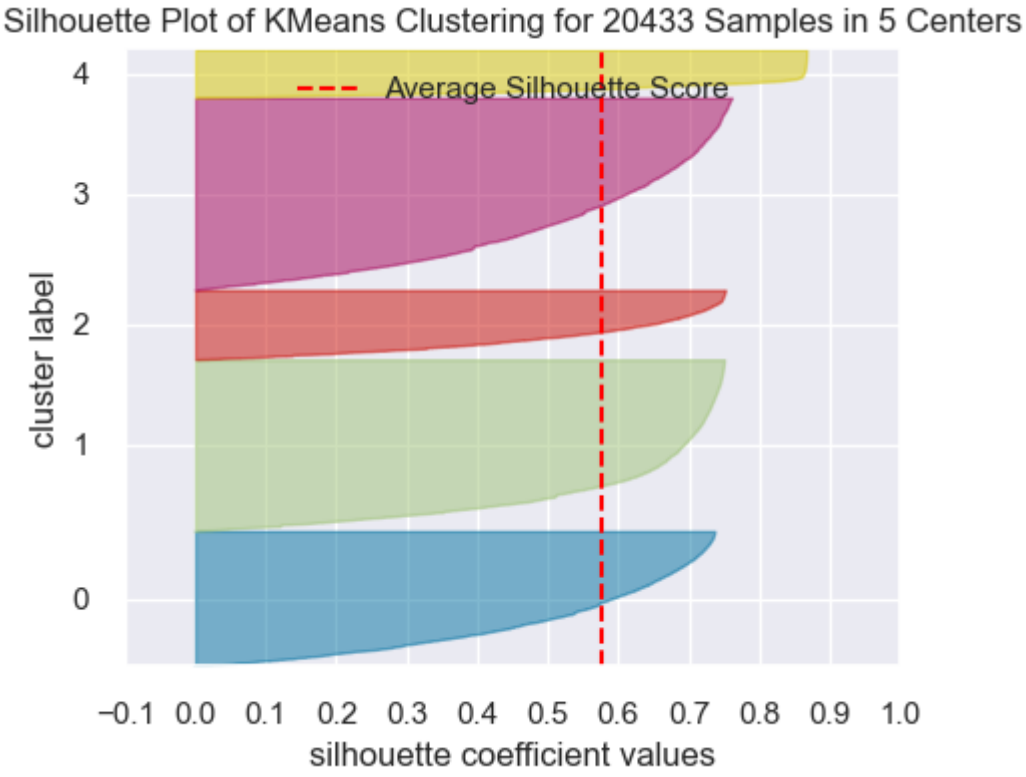
Silhouette Plot of KMeans Clustering for 20433 Samples in 5 Centers
cluster label
4
3
2
1
0
Average Silhouette Score
−0.1 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
silhouette coefficient values

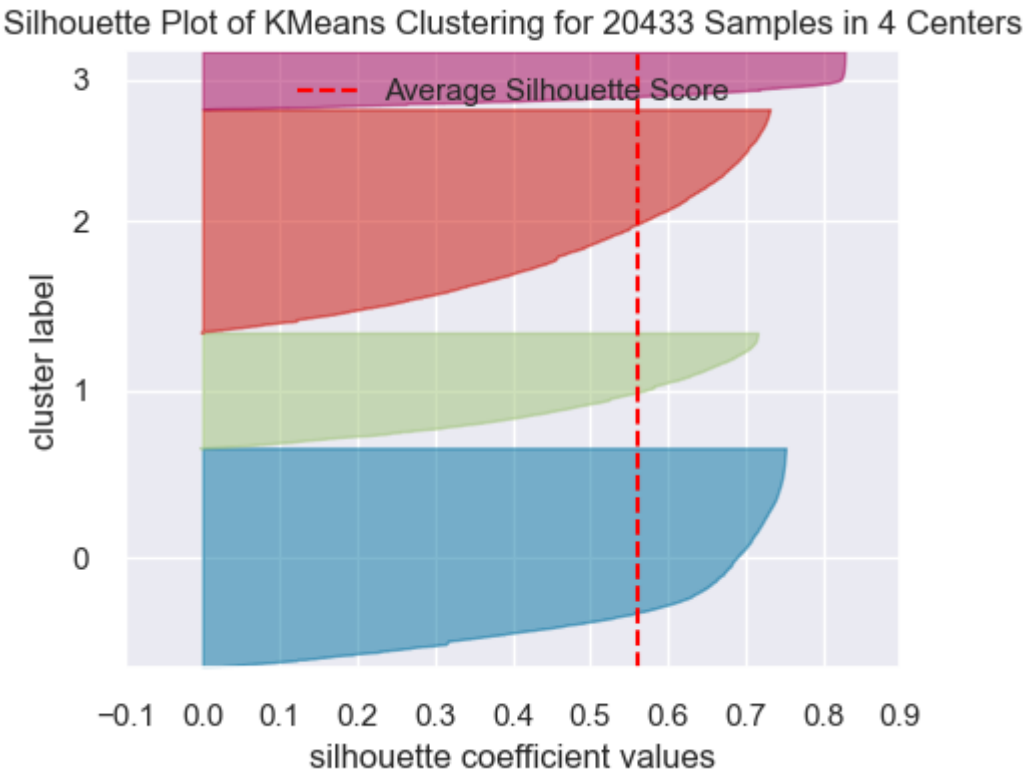


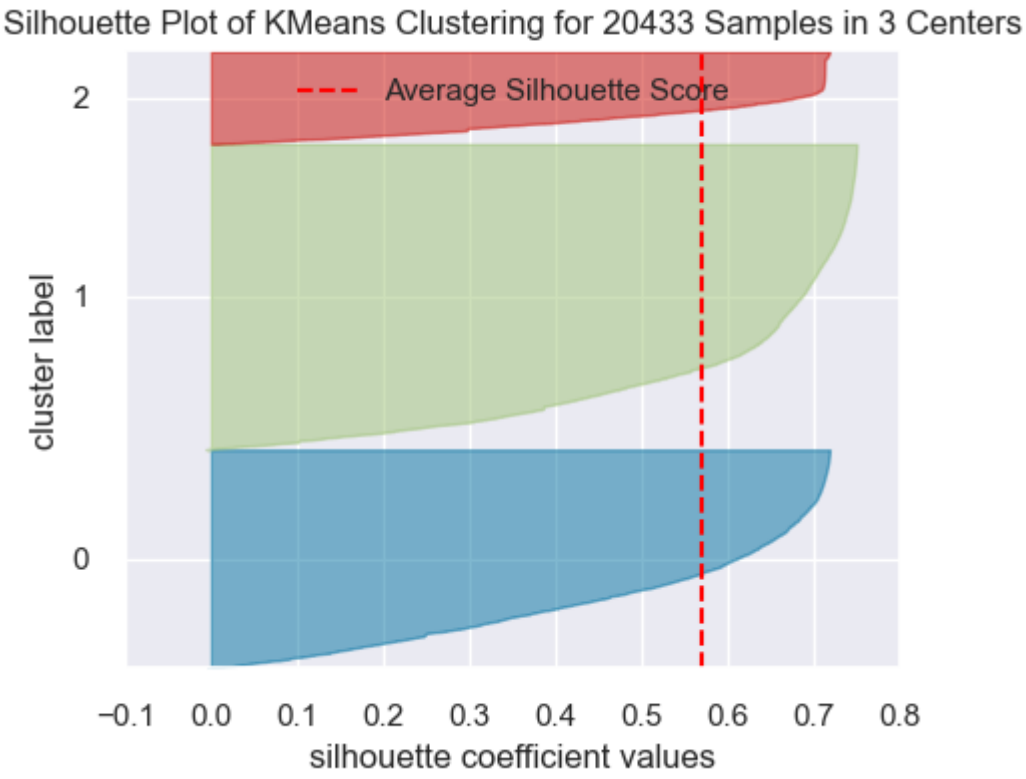


## Justificar o número de clusters

A diferença mais marcante entre os gráficos está no tamanho das silhuetas de cada um. Observa-se que, com 2 clusters, há uma maior discrepância nos tamanhos das silhuetas, indicando uma menor consistência na formação dos grupos. Por outro

lado, com 4 clusters, os tamanhos das silhuetas são mais uniformes, o que sugere que esta configuração proporciona uma divisão mais equilibrada e coesa dos dados, sendo, portanto, a melhor escolha para a quantidade de clusters.

## 1. K-means

In [122…
```
kmeans=KMeans(n_clusters=4,random_state=10) #init='k-means++',
y=kmeans.fit_predict(X)
y
```

Out[122…
```
array([0, 3, 0, ..., 2, 2, 2], shape=(20433,), dtype=int32)
```

In [123…
```
data['Cluster']=y
data.groupby('Cluster').mean()
```

Out[123…

| Cluster | housing_median_age | total_rooms | total_bedrooms | population | househ |
|---|---|---|---|---|---|
| 0 | 31.282156 | 2390.799592 | 407.264946 | 1029.524683 | 389.40 |
| 1 | 13.816872 | 11907.697531 | 2310.693416 | 5927.767490 | 2099.37 |
| 2 | 31.514947 | 1676.651601 | 366.838434 | 1020.807384 | 341.13 |
| 3 | 20.036122 | 4353.580750 | 919.498019 | 2380.515031 | 846.11 |

In [124…
```
### Clusters 0,1,2 e 3
df_0=data[data['Cluster']==0]
df_1=data[data['Cluster']==1]
df_2=data[data['Cluster']==2]
df_3=data[data['Cluster']==3]
```

In [125…
```
df_0.head(3)
```

Out[125…

| | housing_median_age | total_rooms | total_bedrooms | population | households | me |
|---|---|---|---|---|---|---|
| 0 | 41 | 880 | 129 | 322 | 126 | |
| 2 | 52 | 1467 | 190 | 496 | 177 | |
| 3 | 52 | 1274 | 235 | 558 | 219 | |

In [126…
```
df_1.head(3)
```

Out[126…

| | housing_median_age | total_rooms | total_bedrooms | population | households | |
|---|---|---|---|---|---|---|
| 95 | 36 | 5329 | 2477 | 3469 | 2323 | |
| 283 | 22 | 12842 | 2048 | 4985 | 1967 | |
| 508 | 14 | 7355 | 2408 | 3100 | 2051 | |

In [127…

```
import numpy as np
from sklearn.metrics import pairwise_distances

def DBCV(X, labels, metric='euclidean'):
    """
    Density-Based Clustering Validation (DBCV).
    Calcula a métrica de validação baseada em densidade para clusters ger
    """
    def core_distance(point, neighbors, metric):
        distances = pairwise_distances([point], neighbors, metric=metric)
        return np.min(distances[distances > 0])

    def reachability_distance(p, o, neighbors, metric):
        return max(core_distance(p, neighbors, metric), np.linalg.norm(p

    def cluster_density(X_cluster, metric):
        n = len(X_cluster)
        distances = pairwise_distances(X_cluster, metric=metric)
        return np.sum(distances) / (n * (n - 1))

    clusters = np.unique(labels)
    total_density = 0
    for cluster in clusters:
        if cluster == -1:  # Ignore noise
            continue
        cluster_points = X[labels == cluster]
        density = cluster_density(cluster_points, metric)
        total_density += density

    return total_density / len(clusters)
```

# 2. DBScan

In [128…

```
num_pipeline = Pipeline(
    [
      ("imputer", SimpleImputer(strategy="median")),
    ]
)
df_prepared = num_pipeline.fit_transform(x)
df_prepared = preprocessing.normalize(df_prepared)
```

In [129…

```
from sklearn.decomposition import PCA

pca = PCA(n_components = 2)
df_principal = pca.fit_transform(df_prepared)
df_principal = pd.DataFrame(df_principal)
df_principal.columns = ['P1', 'P2']
df_principal
```

Out[129…

| | P1 | P2 |
|---|---|---|
| **0** | -0.017062 | -0.000235 |
| **1** | 0.001782 | -0.004042 |
| **2** | -0.014778 | -0.000756 |
| **3** | -0.014986 | -0.000337 |
| **4** | -0.014079 | -0.000837 |
| **...** | ... | ... |
| **20428** | 0.005517 | -0.001245 |
| **20429** | -0.008732 | -0.000447 |
| **20430** | 0.008321 | -0.002719 |
| **20431** | 0.005041 | -0.003352 |
| **20432** | 0.016689 | -0.002132 |

20433 rows × 2 columns

In [130…

```
db=DBSCAN(eps=0.5,min_samples=10).fit(data)
labels=db.labels_
```

In [131…

```
from matplotlib import colormaps
cmap=colormaps.get_cmap('Spectral').resampled(10)

plt.scatter(x[:, 0], x[:, 1],
            c= labels.astype(float), edgecolor='none', alpha=0.5,
            cmap=cmap)
plt.xlabel('component 1')
plt.ylabel('component 2')
plt.colorbar(label="Label Color Scale")
plt.show()
```

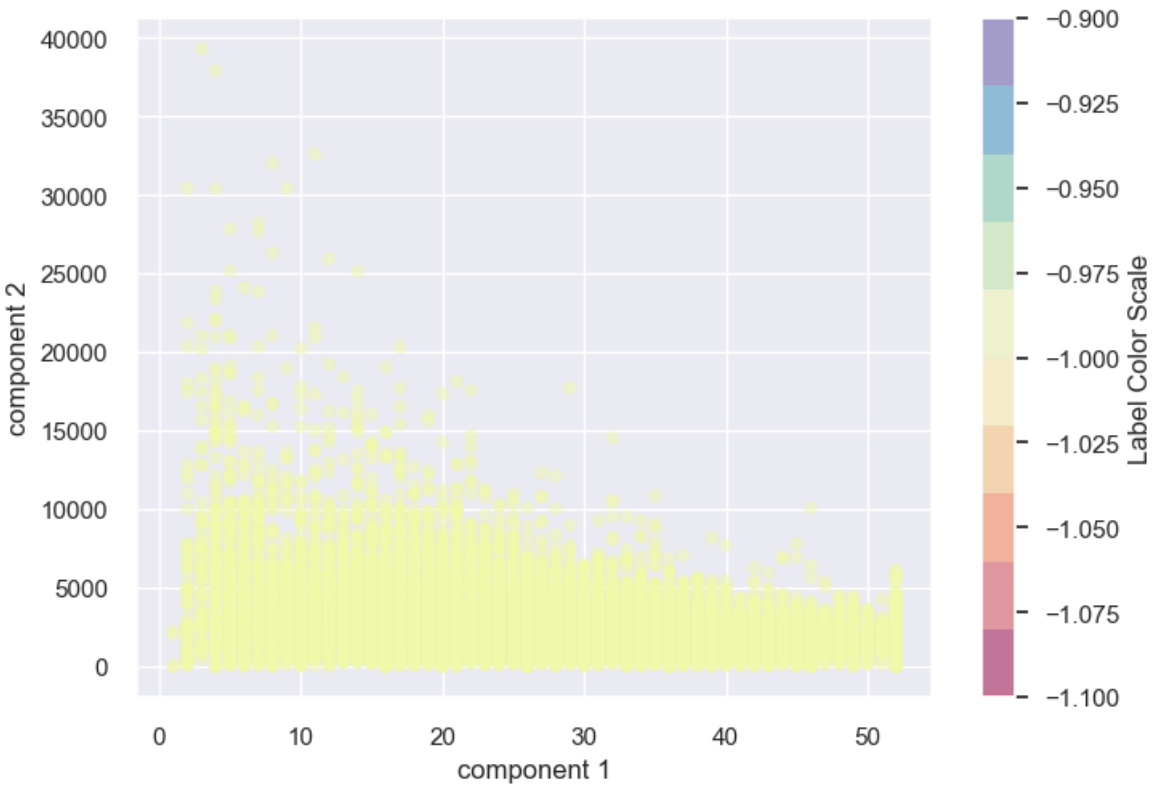


# Compare os dois resultados, aponte as semelhanças e diferenças e interprete

## K-means recuperou 4 grupos distintos já o dbscan não conseguiu recuperar

### K-means

- facil de ser implementado e interpretado
- é mais escalavel mais eficiente
- requer que o usuario diga inicialmente o n° de clusters *sensivel a outliers

### DBScan

- simples e facil de ser implementado
- não requer que o usuario diga p n° de cluster *não é sensivel a outlires

O algoritmo K-means é um método de aprendizado de máquina supervisionado que determina o número de centróides kk, atribuindo cada ponto de dados ao cluster mais próximo e buscando minimizar a distância total dos pontos aos centróides. Em contraste, o DBSCAN (Density-Based Spatial Clustering of Applications with Noise) é baseado na densidade de pontos, identificando clusters como conjuntos densos de pontos conectados. Ele é capaz de dividir regiões densas em clusters, encontrando agrupamentos com formas arbitrárias, mesmo em bases de dados com ruído.

# Além do índice de silhueta, outras duas métricas de validação foram utilizadas para comparar os resultados:

Dendrograma - O dendrograma é uma representação gráfica em forma de árvore que demonstra os agrupamentos formados a cada etapa do processo hierárquico e seus níveis de similaridade. Analisando o dendrograma, é possível identificar que os dados foram agrupados em quatro grandes grupos, representando bem as divisões naturais do conjunto de dados.

KElbowVisualizer - O método do cotovelo, representado pelo KElbowVisualizer, avalia a proximidade dos pontos dentro de cada cluster. Observando o gráfico gerado, o ponto ideal para kk é indicado em 3 ou 4 clusters, com k=4k=4 apresentando o melhor desempenho em termos de tempo de resposta e consistência do algoritmo.

# Comparação com o Índice de Silhueta

- O índice de silhueta mede a qualidade dos clusters considerando a distância entre os centróides e os pontos que os cercam. Ao analisar os gráficos, k=4k=4 apresentou silhuetas mais uniformes e bem distribuídas, indicando uma melhor configuração de agrupamento.

# Validação para DBSCAN

Para o algoritmo DBSCAN, uma métrica mais adequada é o DBCV (Density-Based Cluster Validation), que avalia a qualidade dos clusters com base na densidade dos pontos e não apenas na distância. Essa métrica é particularmente útil para bases de dados com ruído, pois captura a forma dos agrupamentos e considera variações de densidade.

## Com base nos resultados das métricas de validação analisadas (índice de silhueta, dendrograma e KElbowVisualizer), o valor ideal para k nos agrupamentos é 4. Essa escolha oferece a melhor combinação de consistência entre os clusters e eficiência na resposta do algoritmo.

In [132…
```
df=data.drop(['Cluster'],axis=1)
```

In [133…
```
plt.figure(figsize=(14, 5))
plt.grid(False)
dendrogram = sch.dendrogram(sch.linkage(df, method='ward')) #, labels=df.
```

```
plt.title('Dendrogram')
plt.ylabel('Euclidean Distance')
```

Out[133… `Text(0, 0.5, 'Euclidean Distance')`

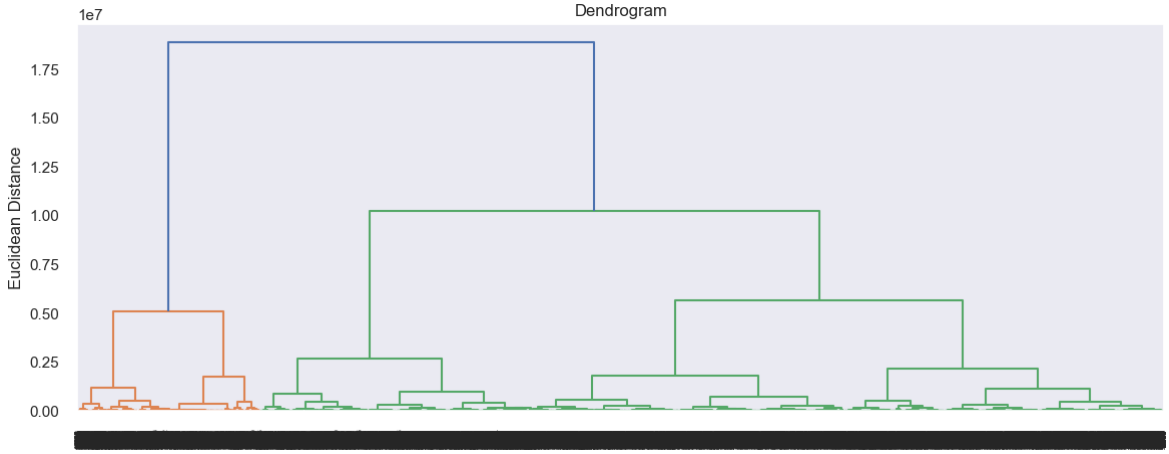


In [134…
```
Wcss=[]
for i in range(1,11):
    kmeans=KMeans(n_clusters=i,init='k-means++',random_state=9)
    kmeans.fit(x)
    Wcss.append(kmeans.inertia_)
print(Wcss)
```

```
[272394861195557.38, 85139069740659.94, 38736688028295.42, 21111318378341.
402, 12269251877454.537, 8758499004866.465, 6471603906594.477, 49237636503
77.528, 3785972457034.5024, 3163284787015.993]
```

In [135…
```
sns.set()
plt.plot(range(1,11),Wcss)
plt.title('Método do Cotovelo')
plt.xlabel('Número Clusters')
plt.ylabel('WCSS')
plt.show()
```

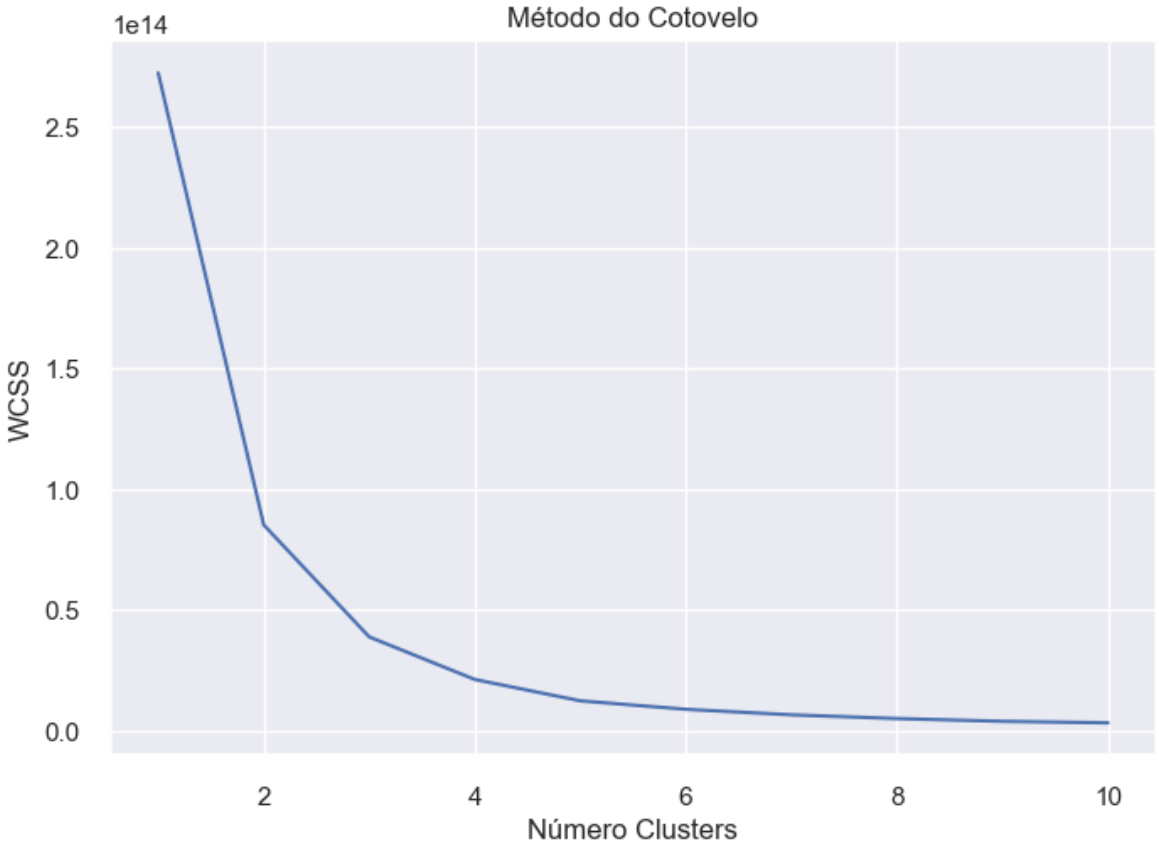


In [136…

```
from yellowbrick.cluster import KElbowVisualizer
el = KElbowVisualizer(KMeans(), k=10)
el.fit(df)
el.show();
```

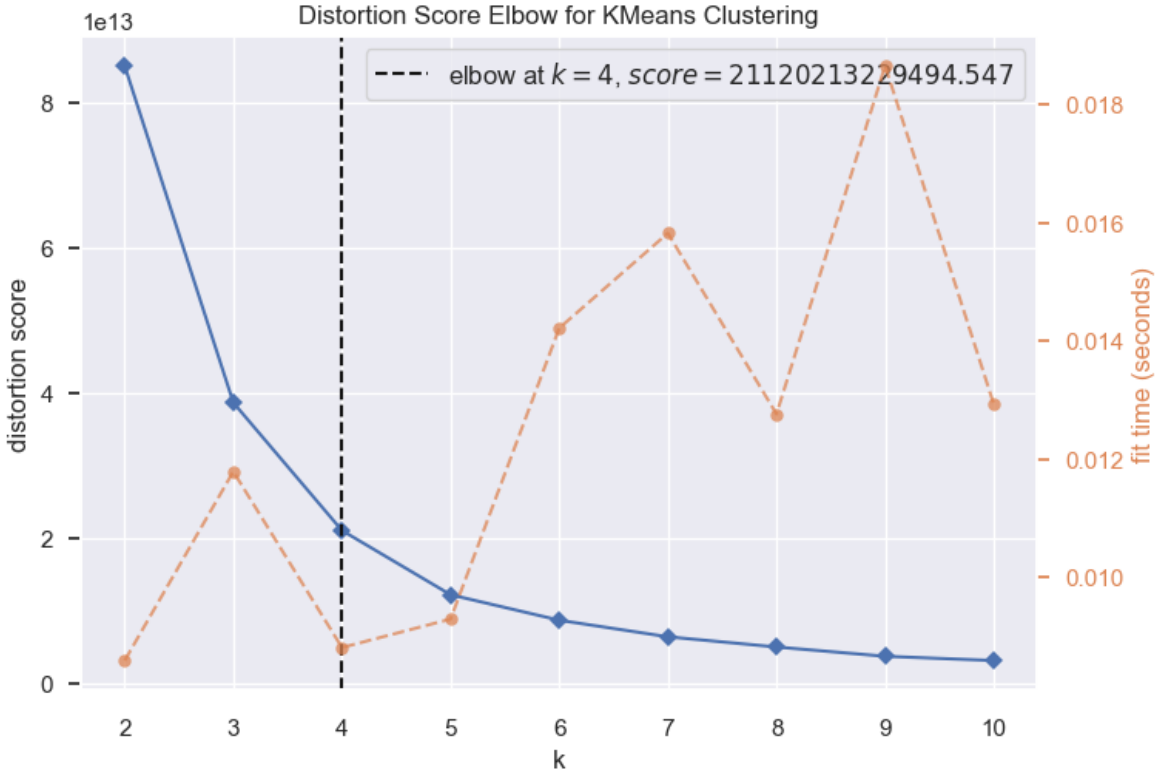


# O Índice de Silhueta é adequado para escolher o número de Clusters no

# DBSCAN?

Resposta: Quando não existem rótulos disponíveis, é comum recorrer a métricas objetivas, como o Silhouette Score, para avaliar e decidir sobre o resultado final de um agrupamento. O Silhouette Score é uma métrica que mede a coesão e separação dos clusters, com valores variando entre -1 e 1. No entanto, ele não considera o ruído no cálculo e baseia-se exclusivamente em distâncias.

Como o DBSCAN é um algoritmo baseado em densidade, a dependência de distâncias viola um pressuposto fundamental desse método. Ignorar o ruído no cálculo da métrica compromete a avaliação da qualidade dos clusters em técnicas baseadas em densidade.

Portanto, métricas como o Silhouette Score não são **adequadas para medir a qualidade dos agrupamentos** gerados pelo DBSCAN.

# Medidas de Similaridade

1. Definição do Problema Um problema apresenta 10 séries temporais distintas, que precisam ser agrupadas em 3 grupos com base no critério de similaridade, utilizando o valor máximo da correlação cruzada entre elas. Passos para calcular a similaridade:

- Etapa 1: Para cada par de séries temporais, aplicar um deslocamento (lag) em unidades de tempo.
- Etapa 2: A cada deslocamento, calcular a correlação de Pearson entre as duas séries.
- Etapa 3: Repetir o processo de deslocamento e cálculo da correlação até obter uma curva de correlação cruzada para cada par de séries.
- Etapa 4: Identificar o ponto de maior correlação na curva, que representará o valor máximo de correlação cruzada entre as séries.
- Etapa 5: Usar os valores máximos de correlação como métrica de similaridade entre as séries temporais.

# Algoritmo de Clusterização

Algoritmo sugerido: KNN (K-Nearest Neighbors)

- O KNN é adequado para estimar densidades, verificando regiões de alta e baixa densidade. Ele fornece um índice de similaridade baseado em distância com valores que variam de -1 a 1.
- Justificativa: É eficaz para dados onde a proximidade entre os valores de similaridade determina o agrupamento.

# Algoritmo sugerido: DTWclust (Dynamic Time Warping Clustering)

- O DTWclust utiliza técnicas relacionadas à distância dinâmica e oferece implementações de agrupamentos particionais e hierárquicos.
- Justificativa: Ele pode ser facilmente personalizado com métricas de distância específicas e definições de centróides, sendo uma escolha robusta para séries temporais.

# Caso de Uso

- Um exemplo de aplicação seria agrupar séries temporais relacionadas ao clima, como padrões anuais de temperatura, ou ciclos de compra e venda em diferentes períodos de tempo. Esses dados podem ser usados para identificar tendências sazonais ou comportamentais.

# Outra Estratégia para Medir Similaridade

1. Definição da Estratégia Medir a similaridade entre séries temporais com base no comportamento de subida e descida em relação ao tempo.

Passos para implementar a estratégia:

- Etapa 1: Identificar o movimento das séries temporais (variações positivas ou negativas ao longo do tempo).
- Etapa 2: Normalizar as séries temporais para reduzir o impacto de valores extremos.
- Etapa 3: Agrupar os movimentos das séries com base na sincronia entre elas, comparando os padrões de subida e descida ao longo do tempo.
- Etapa 4: Utilizar a correlação de Pearson como métrica de similaridade para quantificar o alinhamento dos movimentos.
- Etapa 5: Utilizar o valor máximo de correlação (entre -1 e 1) para identificar o grau de similaridade entre as séries.

Essa abordagem considera a sincronia do comportamento das séries temporais, independentemente do ruído ou deslocamentos, permitindo uma análise mais contextual das similaridades.

In [ ]: